

Linear Algebra-Ega2

1 线性变换

向量是严格的列向量: $x \in \mathbb{R}^{n \times 1}$

矩阵 $A \in \mathbb{R}^{m \times n}$ 对 x 施加变换写作:

$$y = Ax$$

当我们需要同时对 k 个向量进行相同的变换时, 在代数上, 我们将这个 k 个列向量并排拼接, 形成一个矩阵 $X \in \mathbb{R}^{n \times k}$:

$$X = [x_1 \ x_2 \ \cdots \ x_k]$$

对整个矩阵进行左乘, 等价于对每个列向量独立进行变换:

$$Y = AX = A[x_1 \ x_2 \ \cdots \ x_k] = [Ax_1 \ Ax_2 \ \cdots \ Ax_k]$$

结果 $Y \in \mathbb{R}^{m \times k}$ 的每一列, 就是对应原向量的变换结果

Step 1: 代数计算

$$\begin{aligned} A &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \vec{v} = \begin{bmatrix} 3 \\ 2 \end{bmatrix}, \vec{m} = \begin{bmatrix} 4 \\ 1 \end{bmatrix} \\ Av &= \begin{bmatrix} 2 \cdot 3 + 1 \cdot 2 \\ 1 \cdot 3 + 2 \cdot 2 \end{bmatrix} = \begin{bmatrix} 8 \\ 7 \end{bmatrix}, Am = \begin{bmatrix} 2 \cdot 4 + 1 \cdot 1 \\ 1 \cdot 4 + 2 \cdot 1 \end{bmatrix} = \begin{bmatrix} 9 \\ 6 \end{bmatrix} \\ X &= \begin{bmatrix} 3 & 4 \\ 2 & 1 \end{bmatrix} \\ AX &= \begin{bmatrix} 2 \cdot 3 + 1 \cdot 2 & 2 \cdot 4 + 1 \cdot 1 \\ 1 \cdot 3 + 2 \cdot 2 & 1 \cdot 4 + 2 \cdot 1 \end{bmatrix} = \begin{bmatrix} 8 & 9 \\ 7 & 6 \end{bmatrix} \end{aligned}$$

Step 2: 行与列的视角问题

我们从纯粹的代数计算来说:

$$Y = AX = A[x_1 \ x_2 \ \cdots \ x_k] = [Ax_1 \ Ax_2 \ \cdots \ Ax_k]$$

是成立的

我们这里会发现矩阵和向量的关系 $\rightarrow$

($\cdot$)

我们知道矩阵变换的代数

公式:

$$f(ax + by) = af(x) + bf(y) = bf(y) + af(x)$$

其实行与列是不同视角看同一个结果的方式? 上述其代数是标准的行·列视角, 现在我们切换成列视角:

$$A = e_1 + e_2$$

$$Av = e_1 \cdot v[0] + e_2 \cdot v[1] = y$$

这个视角我们发现它是非常标准的线性变换代数式也就是说列视角才是矩阵变换线性变换的本来形态

y 的最终位置是由 n 份 e_1 + k 份 e_2 组成

$$Av = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \vec{v} = 3 \cdot \begin{bmatrix} 2 \\ 1 \end{bmatrix} + 2 \cdot \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 8 \\ 7 \end{bmatrix}$$

那么 AX 呢?

$$Y = AX$$

$$Y_{col1} = Av$$

$$Y_{col2} = Am$$

思考一个问题:

如果 $a_1 = k \cdot a_2$ 呢?

$$Av = \vec{a}_1 \cdot v[0] + \vec{a}_2 \cdot v[1] = k\vec{a}_2 \cdot v[0] + \vec{a}_2 \cdot v[1] = (k \cdot v[0] + v[1])\vec{a}_2 = y$$

最终目的地 y 只会沿着 e_2 做伸缩动作 $= \det(A) = 0$ y 被降维了而且维度只是 1, Rank = 1 ?

如果一个变换存在降维, 那么是否有可能使用向量完全消失呢, 把向量拍到零空间呢?

3: Rank, Null Space, Nullity

Rank 是与矩阵的维度直接相关

$$A \in \mathbb{R}^{m \times n}$$

一个矩阵的维度与列向量数量直接相关如果矩阵的每列都是”独一”的不满足被其他列代数替换性 $\rightarrow c_1 = kc_2$ 也就是列不存在线性关系

那么 Rank = min(m, n) m 是维度是列向量的元素数, 如果存在 $c_1 = kc_2$ 那么要 - 存在线性关系类数而 Rank 就是矩阵变化之后 $y = Ax$ 所有 y 向量集合的维度

Null Space 是经过矩阵运算之后压回原点的原始向量 x 集合

Nullity 压回原点的原始向量 x 集合的维度这个维度是它们物理位置拼凑出了一个什么形状? 这个形状是几维的

$$\text{我们回到代数式 } (k \cdot v[0] + v[1])\vec{a}_2 = y$$

满足这个代数式的矩阵 Rank = 1

$$\begin{aligned} \text{那么什么样子的向量会被压到 Null Space 呢? 也就是 } (k \cdot v[0] + v[1])\vec{a}_2 &= 0 \text{ and } \vec{a}_2 \neq 0 \\ &= k \cdot v[0] + v[1] = 0 \\ &= k \cdot v[0] = -v[1] \end{aligned}$$

很明显 $v[0]$ 和 $v[1]$ 是存在线性关系的
向量 v 是存在两个分量的 $\in \mathbb{R}^2$

$$\text{但 } = k \cdot v[0] = -v[1]$$

可以代数转换成 $y = -kx$ 是一个线性关系函数, 是一条直线

也就是说在这条直线上的所有向量集合都会被压到零空间

只要变换存在降维 (Rank(A) < n), 就必然存在非零向量被拍到零空间

向量真的死了吗? 向量是客观存在的实体 (比如空间里的一根箭)。矩阵是一次主观的“观测动作”或“投影动作” (比如拿手电筒打影子)。当一个向量不幸落入“零空间 (Null Space)”时, 并不是这个向量在客观物理世界中粉碎了。而是矩阵 A 的观测方式太狭隘了 (因为它降维了, Rank 不足), 导致它完全捕捉不到这个向量在特定方向上的信息。零空间 (死亡名单), 本质上就是矩阵 A 的 ** “观测盲区” **

2 复数

$$z_1 = r_1 e^{i\theta_1}, z_2 = r_2 e^{i\theta_2}$$

$$= z_1 \cdot z_2 = r_1 \cdot r_2 \cdot e^{(i\theta_1 + i\theta_2)}$$

A^2x 的结果我们一眼就能看出来先旋转 180 度之后再拉伸 2 倍
 $(2i)(2i)x = 4i^2x$ 180 度之后再拉伸 2 倍 $= 4i^2x i^2 = -1$
 $4i^2x = -4x$

假如这个矩阵 A 是 2x2 存在两个特征值

λ_1, λ_2

我们知道特征向量的定义是不改变方向也就是说在同一方向做伸缩动作

如果 $\lambda_1 = 2i = -1$ 这是符合这个定义的翻转也是一种负向的拉伸

为了“抵消”掉这个逆时针旋转 90 度带来的虚数部分，保证整个宏观物理系统依然是实数底色，你凭借直觉猜测，这个矩阵 A 必定还隐藏着另一个什么样的特征值 λ_2 ？它对应的物理动作是什么？这个问题我没明白??

我刚才没表达清楚我觉得那么代表“顺时针转 90 度，拉伸 2 倍”的那个复数 λ_2 ，在代数上应该写成什么？

应该写成 $2(-i) = -2i$ 这个-是负号不是减法

我们现在看共轭公式：

$$\lambda_1 = a + bi \quad \lambda_2 = a - bi$$

a 是一个常数量它是一个线性距离也就是离出发点的距离那么我们把相加

$\lambda_1 + \lambda_2 = a + bi + a - bi = 2a$ 为什么一个共轭操作不是完全抵消会成为 2 倍的 a 呢？

$\lambda_1 \cdot \lambda_2 = (a + bi) \cdot (a - bi) = a^2 - abi + abi - bi^2 = a^2 - b^2 \cdot (-1) = a^2 + b^2$??? 很明显是常数结果但依然没有完全抵消？

3 Trace and Determinant

$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$ 它存在两个特征值 λ_1 和 λ_2

特征多项式 $\det(\lambda I - A)$

$$\begin{aligned} p(\lambda) &= \det \begin{bmatrix} \lambda - a & -b \\ -c & \lambda - d \end{bmatrix} \\ &= (\lambda - a)(\lambda - d) - (-b)(-c) \\ &= (\lambda - a)(\lambda - d) - bc \\ &= \lambda^2 - \lambda d - a\lambda + ad - bc \\ &= \lambda^2 - (a + d)\lambda + (ad - bc) \end{aligned}$$

为 λ_1, λ_2 是这个多项式的根转换成因式分解为：

$$p(\lambda) = (\lambda - \lambda_1)(\lambda - \lambda_2) \quad (1)$$

$$= \lambda^2 - (\lambda_1 + \lambda_2)\lambda + \lambda_1\lambda_2 \quad (2)$$

so:

$$a + d = (\lambda_1 + \lambda_2)$$

$$(ad - bc) = \lambda_1\lambda_2$$