

Linear Algebra-Ega2

1 破裂日 (Defective Matrix)

$$A = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}$$

尝试对其进行对角化：

Step 1: Solve λ (求特征值与代数重数)

$$\begin{aligned} \det(A - \lambda I) &= 0 \\ (2 - \lambda)^2 &= 0 \end{aligned}$$

解得特征值为重根 $\lambda = 2$ 。

因为因子的指数为 2，所以：**代数重数 = 2**。

Step 2: Solve egv (求特征向量与几何重数)

将 $\lambda = 2$ 代入 $A - \lambda I$ ：

$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$$

显然，该矩阵的 Rank (秩) = 1。

根据定理：**几何重数 = 维度 n - Rank = 2 - 1 = 1**。

求解齐次方程组 $(A - 2I)x = 0$ ：

$$\begin{cases} 0x + y = 0 \\ 0x + 0y = 0 \end{cases}$$

解得： $y = 0$ ， x 可以为任何非零数。

得到**唯一**的基础解系 (特征向量)： $\vec{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$

Step 3: 为什么 $g_i < a_i$ 不能对角化？

对角化的核心公式是： $A = P \cdot D \cdot P^{-1}$ 。

其中矩阵 P 必须是由 n 个特征向量拼成的可逆矩阵： $P = [\vec{e}_1 \ \cdots \ \vec{e}_n]$ 。

要让 P 可逆 (即能算出 P^{-1})， P 必须满足：

1. 内部的列向量必须**线性无关** (例如不能存在 $\vec{e}_i = k \cdot \vec{e}_j$ 的共线情况)。
2. 矩阵必须满秩，即 $\det(P) \neq 0$ (不能出现降维塌陷)。

Step 4: 到底什么是对角化？它和 P 以及 P^{-1} 的几何关系

对角化就是找到矩阵 A 的“极简形态” D (由特征值组成的对角矩阵)。

代数推导：

如果 P 可逆，对角化公式为： $A = P \cdot D \cdot P^{-1}$ 。

左右同乘 P : $AP = P \cdot D \cdot P^{-1}P \implies AP = PD$

左乘 P^{-1} : $P^{-1}AP = P^{-1}PD \implies D = P^{-1}AP$

几何直觉 (翻译器理论):

我们把一个普通向量 $\vec{x}$ 放到公式最右边来观察变换过程: $A\vec{x} = P \cdot D \cdot P^{-1}\vec{x}$ 。

矩阵乘法是**从右向左**执行的, 这完美对应了三个步骤:

1. P^{-1} (**入境翻译器**): 把向量 $\vec{x}$ 从“标准基环境”翻译并拉拽到“ P 特征向量基环境”中。
2. D (**极简处理核心**): 在特征向量的专属世界里, 变换变得极其简单! 不需要复杂的旋转扭曲, 只需要沿着各个轴做简单的缩放 (乘以特征值)。这就是到达目的地的捷径。
3. P (**出境翻译器**): 处理完毕后, 用 P 把结果从“特征环境”重新翻译回我们熟悉的“标准基环境”。

从几何视角分析, A 是基于标准基坐标系的、极其混乱复杂的转换; 而 D 是基于特征向量基坐标系的、最为简单的转换 (只有单纯的拉伸/压缩)。

但无论走哪条路 (直接用 A , 或者走 $P \rightarrow D \rightarrow P^{-1}$ 的捷径), 它们最终都会到达**同一个绝对的向量地址**。对角化, 就是为了寻找这条“降维打击”般的捷径!

Step 5: 这个矩阵的几何行为是什么:

从 A 矩阵两个列向量初看: 应该是先拉伸之后向右上提? 因为 $e_1 = \begin{bmatrix} 2 \\ 0 \end{bmatrix} = 2 \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 是非常标准的拉伸动作但 $e_2 \cdot x = 1$ 而非 0 则证明路径整体上移?

2 代数重数与几何重数

已知矩阵 $A = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$, 判断其是否可对角化。

第一步: 求特征值与代数重数

构建特征方程: $\det(A - \lambda I) = 0$

$$\begin{vmatrix} 2 - \lambda & 0 \\ 0 & 2 - \lambda \end{vmatrix} = 0$$

化简得多项式: $(2 - \lambda)^2 = 0$

解得特征值为 $\lambda = 2$ 。

- **代数重数:** 看特征多项式中 $(\lambda - 2)$ 这个因子的**最高次幂**。因为这里是平方 (2 次方), 所以 $\lambda = 2$ 的**代数重数 = 2**。

第二步: 求特征向量与几何重数

将 $\lambda = 2$ 代入, 构建齐次线性方程组 $(A - \lambda I)x = 0$:

$$\begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

展开即为:

$$\begin{cases} 0x_1 + 0x_2 = 0 \\ 0x_1 + 0x_2 = 0 \end{cases}$$

• 计算几何重数 (重点):

此时系数矩阵 $(A - 2I)$ 是一个全零矩阵, 其秩 $r = 0$ 。

矩阵的阶数 $n = 2$ (未知数个数)。

根据定理: 特征空间的维数 (几何重数) $= n - r$

所以, 几何重数 $= 2 - 0 = 2$ 。

第三步: 求基础解系

因为方程组的秩为 0, 说明 x_1 和 x_2 都是自由变量 (可以取任意不全为 0 的数)。

我们可以取两组线性无关的向量作为基础解系:

$$p_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad p_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

这说明特征空间是二维的。

结论:

对于特征值 $\lambda = 2$, 其 几何重数 (2) = 代数重数 (2)。

因此, 矩阵 A 可以找到 2 个线性无关的特征向量, 该矩阵可对角化 (实际上它本身就是对角阵)。

问一个一直困扰我很久的问题为什么矩阵乘法的运算规则是行 * 列 $A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$

我在理解矩阵时会以列向量的模式理解也就是矩阵 A 是有 $e_1 = \begin{bmatrix} a \\ c \end{bmatrix}, e_2 = \begin{bmatrix} b \\ d \end{bmatrix}$ 组成是基底

向量我们知道标准矩阵 $I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ A 和 I 的变化关系是 $I.e_1 \rightarrow A.e_1, I.e_2 \rightarrow A.e_2$ 对于一个向量 $\vec{v}$

经过 A 矩阵变化之后 $\rightarrow \vec{v}_n = v.x \cdot A.e_1 + v.y \cdot A.e_2$ 一种向量加法的形态但这个代数形态并不是行 * 列呀?

3 矩阵

1: 矩阵的诞生与矩阵的代数意义?

为什么课题是矩阵与向量矩阵在前向量在后? 因为矩阵的诞生是为了解决代数问题:

存在方程组 a:

$$\begin{cases} 4x + 3y = 8 \\ 4x - y = 5 \end{cases}$$

a 存在一个重要的代数性质”线性”也就是满足可加性、齐次性

假如我们把方程组 a 的左边抽象成函数 $f(x, y)$:

可加性满足:

$$f(u + v) = f(u) + f(v)$$

齐次性满足: $f(k \cdot u) = k \cdot f(u)$

a 方程可以变化成一个矩阵模式 (这里只有代数意义)

$$A = \begin{bmatrix} 4 & 3 \\ 4 & -1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 8 \\ 5 \end{bmatrix}$$

A 可以通过矩阵乘法规则还原成 a

2: 矩阵模式对于方程组的优势 (数学家为什么要发明矩阵这个概念去表达代数方程组)?

A 是可以还原为 a 的利用矩阵乘法规则

那么我们仔细分析 A 的形态: $A \cdot x = y$

X 完全为代数未知数, x 和 y 是完全的已知数

1: 把未知和已知解耦这里是利用了齐次性 $f(k \cdot x) = k \cdot f(x)$

k 是已知数 $f(x)$ 是未知数?

2: 如果 Y 的系数项非常大那么整个代数运算也会是 $X \cdot Y = Z$ 这种形态 X 依然简单 Y 包含了全部的线性运算规则隔离成了两个整体

3: 矩阵和线性的关系 (可加性、齐次性)

A 是可以还原为 a 所以矩阵形态是天然满足线性的 (或者说 A 是容器, 矩阵乘法规则才是线性的表达)

$$A(u + v) = Au + Av \text{ 和 } A(ku) = k \cdot Au$$

4: 矩阵和几何空间的关系, 为什么矩阵变成了可以表达空间几何变换? 是什么特性造成的?

我们由上已知道矩阵形态是天然满足线性的

所以我们关键的要分析可加性和齐次性在几何上是什么形态表达?

齐次性的几何表现:

$$f(k \cdot v) = k \cdot f(v)$$

齐次性是使用代数乘法的运算如果 v 是一个有方向的数学对象那么 $k \cdot v = v + v + \dots$

我们会发现它会沿这个方向 (如果 k 是负数就是反方向) 做以 v 为单位的伸缩动作这个动作就是直线伸缩动作

v 有起点吗?

我们把 k 设置为 0 , 这就是代数上的起点

$$f(0 \cdot v) = 0 \cdot f(v) = 0$$

在几何上这个起点就是零空间也就是原点

我们需要理解上面这个代数式 f 是线性变化 $0 \cdot v$ 是处于原点的 v

$= 0 \cdot f(v)$ 如果满足齐次性这个等号满足那么结果必然等于 0

所以我们能得到齐次性的几何表现是过原点的直线伸缩动作? 只要一个变换满足齐次性, 它就绝对不能移动原点, 原点必须是变换的不动点。反过来, 所有会移动原点的变换 (比如平移), 必然不满足齐次性, 也就不是线性变换可加性的几何表现:

$$f(u + v) = f(u) + f(v)$$

可加性是使用代数加法而运算加法有一个非常意思的特性 -> 支持对同一个结构的不同数据的多个数学对象进行组合平移 (例如自然数相加 $3 + 4 = 7$ 他们是同一个结构但值不一样

例如 $\vec{v} + \vec{x} = \vec{v}\vec{x}$)

而乘法是复制平移是单方向的但组合平移是多方向的 (或者说是没限制方向的)

$$f(u + v) = f(u) + f(v) = f(v) + f(u)$$

这里我们拿路线为例子 $f(u)$ 和 $f(v)$ 都是一个拥有路线 (有方向) 的目的地先走 $f(u)$ 之后再走 $f(v)$ 到达的最终目的地 = 先走 $f(v)$ 再走 $f(u)$

是天然存在对称性的 (加法也存在对称性) 那么什么几何形状存在两步结构天然对称性的? 平行四边形

所以可加性是任意方向组合平行四边形?

所以当矩阵形态 (重点是矩阵运算规则) 是满足线性的那么矩阵天然适配为线性几何变化, 它只是被发现

4 逆向问题

$$\text{已知 } D = \begin{bmatrix} 3 & 0 \\ 0 & -1 \end{bmatrix}, P = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

1: 求 A

$$A = P \cdot D \cdot P^{-1}$$

$$\det(P) = -1 - 1 = -2$$

$$P^{-1} = \frac{1}{ad-bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} = \begin{bmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} \end{bmatrix}$$

$$A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$$

2: A 的特征值是否真的是 3 和 -1

迹 + 特征多项式 / 韦达定理

$$\lambda_1 + \lambda_2 = 2 \quad (1)$$

$$\lambda_1 \cdot \lambda_2 = -3 \quad (2)$$

带入 3, -1 成立

3: 思考题: 你是从”特征基世界”出发, 构造出标准基下的矩阵。用你的翻译器类比说清楚这个反向过程

$$A\vec{v} = P \cdot D \cdot P^{-1}\vec{v}$$

我们已知 P 和 D 是矩阵特征向量矩阵和特征值对角矩阵

所以我们依然重点要关注 P 到底是什么:

P 最重要的一个特点是它使用基于基础基底 (e1,e2) 的两个特征向量同样撑起了整个以基础基底 (e1,e2) 的平面

$$P = [\vec{g1} | \vec{g2}]$$

$$\text{我们以一个最终向量 } \vec{X} = \begin{bmatrix} p1 \\ p2 \end{bmatrix}$$

那么存在下面的代数关系 (也是几何关系):

$$\vec{v} = \begin{bmatrix} a1 \\ a2 \end{bmatrix}, \vec{v1} = \begin{bmatrix} c1 \\ c2 \end{bmatrix}$$

$$= a1 \cdot e1 + a2 \cdot e2 = c1 \cdot g1 + c2 \cdot g2 = \vec{X}$$

a1,a2,c1,c2 为常量代表步伐

g1, g2 可以进一步展开为

$$g1 = g1_x e1 + g1_y e2$$

$$g2 = g2_x e1 + g2_y e2$$

代数转换一下:

$$= c1 \cdot (g1_x e1 + g1_y e2) + c2 \cdot (g2_x e1 + g2_y e2)$$

$$= [\vec{e1} | \vec{e2}] c1 \cdot \begin{bmatrix} g1_x \\ g1_y \end{bmatrix} + [\vec{e1} | \vec{e2}] c2 \cdot \begin{bmatrix} g2_x \\ g2_y \end{bmatrix}$$

$$= [\vec{e1} | \vec{e2}] (c1 \cdot \begin{bmatrix} g1_x \\ g1_y \end{bmatrix} + c2 \cdot \begin{bmatrix} g2_x \\ g2_y \end{bmatrix})$$

$$[\vec{e1} | \vec{e2}] \begin{bmatrix} a1 \\ a2 \end{bmatrix} = [\vec{e1} | \vec{e2}] (c1 \cdot \begin{bmatrix} g1_x \\ g1_y \end{bmatrix} + c2 \cdot \begin{bmatrix} g2_x \\ g2_y \end{bmatrix})$$

$$\begin{bmatrix} a1 \\ a2 \end{bmatrix} = c1 \cdot \begin{bmatrix} g1_x \\ g1_y \end{bmatrix} + c2 \cdot \begin{bmatrix} g2_x \\ g2_y \end{bmatrix}$$

$$\begin{bmatrix} a1 \\ a2 \end{bmatrix} = P \begin{bmatrix} c1 \\ c2 \end{bmatrix}$$

P 的列向量 (特征向量) 和标准基张成的是同一个 R^2 空间, 把一个向量翻译回这个空间

P^{-1} 到底是什么?

我们已知 P 是一个翻译器那么 P^{-1} 依然是一个翻译器但我们要使用代数证明 P^{-1} 翻译到什么环境??

同时乘法 P^{-1}

$$P^{-1} \begin{bmatrix} a1 \\ a2 \end{bmatrix} = P^{-1} P \begin{bmatrix} c1 \\ c2 \end{bmatrix}$$

$$= P^{-1} \begin{bmatrix} a1 \\ a2 \end{bmatrix} = \begin{bmatrix} c1 \\ c2 \end{bmatrix}$$

$$P^{-1} \begin{bmatrix} a1 \\ a2 \end{bmatrix} \rightarrow \begin{bmatrix} c1 \\ c2 \end{bmatrix}$$

这个代数式非常清楚的表达了 P^{-1} 的身份把一个向量翻译到特征向量基底空间

那么这个逆向工程就非常清晰了: 我们拥有 P 和 D 我们可以找到 P^{-1}

DP^{-1} 是把向量翻译到特征向量基底空间并到达目的地, P 把这个目的地翻译回 $A(P$ 和 A 在一个张成空间)

5 矩阵的迹

定义: 矩阵 $A \in \mathbb{R}^{n \times n}$

$$tr(A) = \sum_{i=1}^n A_{ii}$$

- 1: 到底什么是迹, 它是为了解决什么问题?

在标准基下 (e_1, e_2):

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

我们要分析一个问题: a, b, c, d 这些常数项的变化会给整个矩阵带来什么变化?

$$A\vec{v} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} ax + by \\ cx + dy \end{bmatrix}$$

$$\text{我们设 } A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$\begin{bmatrix} ax + by \\ cx + dy \end{bmatrix} = \begin{bmatrix} x \\ y \end{bmatrix}$$

我们改变 $a, b \neq 0$

$$= \begin{bmatrix} x + by \\ y \end{bmatrix}$$

所以我们发现新的 y 依然是 y 新的 x 是 $x + by$: 例子:

$$\begin{bmatrix} 1 \\ 1 \end{bmatrix} (v_1) \rightarrow \begin{bmatrix} b \cdot (1) \\ 1 \end{bmatrix} (v_2) \quad v_2 \text{ 对比 } \vec{1} \text{ 发生了水平平移所以 } b \text{ 控制了水平剪切程度}$$

$$c: \begin{bmatrix} x \\ cx + y \end{bmatrix} \text{ 发生了垂直剪切}$$

$$a: = \begin{bmatrix} ax \\ y \end{bmatrix} \text{ 拉伸了 } x \text{ 轴长是水平拉伸}$$

$$d: = \begin{bmatrix} x \\ by \end{bmatrix} \text{ 拉伸了 } y \text{ 轴长是垂直拉伸}$$

我们现在知道 a, b 是倍数关系:

$$tr(A) = a + d$$

我们就能清晰的明白: $a + d$ 或 $\sum_{i=1}^n A_{ii}$ 是剔除剪切变化之后的总伸缩率 (这就是一种解耦的表现 $\rightarrow$ 改变面积变化和改变形状变化) 迹到底解决了什么问题: 对矩阵变化之后的伸缩率的一种直观表现?

- 2 迹与基的关系:

2.1 在回答迹与基的关系之前, 我们来弄明白什么叫换基和换基的目的?

存在一个绝对的地址可以使用绝对向量 X 表达

A 矩阵是基于标准基到达 X 的线性变换

B 矩阵是基于 P (基底) 到达 X 的线性变换

这是同一种抽象的线性变化, 在不同基下的矩阵表示

子问题 2.1: B 的代数表达是什么 (基于 A 和 P), 为什么这么表达?

2.1.1 : P 是什么, Pv 是什么?

A 是基于标准基底 E 的线性变换 $[e_1 | e_2]$

向量 $\vec{m} = \begin{bmatrix} x \\ y \end{bmatrix}$ 存在于标准基环境

向量 $\vec{v} = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}$

因为 P 的身份是基底 $[p_1 | p_2]$

但 P 还有另一种非常重要的特性: 它本身是基于 E 的一个抽象线性变换也就是说如果 P 是存在的那么它也能张成整个空间

那么对 X (绝对向量来说)

$$X = xe_1 + ye_2 = c_1p_1 + c_2p_2$$

$$m = Pv$$

那么 Pv 就是 m 是同一个对象, 不同的视角, P 是翻译回 E 环境的翻译器

2.1.2: B 的代数表达; $Am = APv$ 是成立的 (基于 2.1.1)

它们是 E 环境下完全相同的变换

已知 B 是 P 基底的线性变换

我们需要把

$$P^{-1}Am = P^{-1}APv$$

$$m = Pv$$

上面的代数证明来 P^{-1} 就是翻译回 P 环境的翻译器! 那么 $B = P^{-1}AP$

有 2.1.1 和 2.1.2 我们得知 B 和 A 是同一种线性变换 T 的两种表达

$tr(T) = tr(A) = tr(B)$ 迹在不同基底的不变性

• 3 迹与连续变化 XY :

矩阵乘法并不支持交换率 $XYv \neq YXv$

我们也知道迹是线性的总伸缩率 (伸缩率会改变面积, 但剪切变化不会改变面积, 只会改变形状 (item1))

那么 $tr(XY)$ 的一种重要的代数性质是先伸缩一个系数然后再伸缩一个系数是一个连续动作

类似代数式 $s \cdot x \cdot y = s \cdot y \cdot x$ (s 是面积), 这是一种逻辑推导

代数推导:

$$X, Y \in \mathbb{R}^{n \times n}$$

X 的 i 行, j 列的数记 X_{ij}

Y 的 j 行, k 列的数记 Y_{jk}

step1: $tr(XY)$:

$$(XY)_{ik} = \sum_{j=1}^n X_{ij}Y_{jk} \quad (3)$$

$$(XY)_{ii} = \sum_{j=1}^n X_{ij}Y_{ji} \quad (4)$$

$$tr(XY) = \sum_{i=1}^n \left(\sum_{j=1}^n X_{ij}Y_{ji} \right) \quad (5)$$

Y 的 j 行, k 列的数记 Y_{jk}

X 的 i 行, j 列的数记 X_{ij}

step2: $tr(YX)$:

$$(YX)ik = \sum_{i=1}^n Y_{ij} X_{jk} \quad (6)$$

$$(YX)jj = \sum_{i=1}^n Y_{ji} X_{ij} \quad (7)$$

$$tr(YX) = \sum_{j=1}^n \left(\sum_{i=1}^n Y_{ji} X_{ij} \right) \quad (8)$$

$\sum_{j=1}^n (\sum_{i=1}^n Y_{ji} X_{ij})$ 是基于常数的加法与乘法的混合运算是支持交换率和结合律的
 $= \sum_{j=1}^n (\sum_{i=1}^n X_{ij} Y_{ji})$
 $= \sum_{i=1}^n (\sum_{j=1}^n X_{ij} Y_{ji}) = tr(XY)$

- 4 为什么 $tr(A) = \lambda_1 + \lambda_2$?
 A 可以对角化 $tr(A) = tr(PDP^{-1})$
 $tr(A) = tr(XY) = tr(YX) = tr(P^{-1}PD) = tr(D) = \lambda_1 + \lambda_2 + \dots$
 但我们也可以使用另一种视角也就是迹在不同基底的不变性
 $tr(A) = tr(B) = tr(P^{-1}AP) = tr(P^{-1}PDP^{-1}P) = tr(D)$
- 5 思考为什么 $det(A) = \lambda_1 \cdot \lambda_2$?
 $det(A) = det(PDP^{-1})$
 $= det(XY) = det(X)det(Y)$ (item3)
 $= det(P)det(DP^{-1}) = det(P)det(D)det(P^{-1}) = ()det(P)det(P^{-1})det(D) = det(D)$